



저작자표시-비영리-동일조건변경허락 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.
- 이차적 저작물을 작성할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



동일조건변경허락. 귀하가 이 저작물을 개작, 변형 또는 가공했을 경우에는, 이 저작물과 동일한 이용허락조건하에서만 배포할 수 있습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

이학석사학위 논문

비지도학습 기반 센서데이터의 이상치 탐지 비교 연구

Comparison Study of Unsupervised based Anomaly
Detection in Sensor Data

2023년 8월



인하대학교 대학원

통계학과(통계전공)

고 건 우

이학석사학위 논문

비지도학습 기반 센서데이터의 이상치 탐지 비교 연구

Comparison Study of Unsupervised based Anomaly
Detection in Sensor Data



지도교수 유 동 현

이 논문을 석사학위 논문으로 제출함

이 논문을 고건우의 석사학위논문으로 인정함.

2023년 4월 13 일



주심 온일상 (인)

부심 유동현 (인)

위원 조성훈 (인)

목차

1. 서론	3
2. 비지도학습 기반 이상치 탐지 방법론	5
2.1. OC-SVM	5
2.2. SVDD	6
2.3. Autoencoder	8
2.4. AnoGAN	9
2.5. DeepSVDD	10
2.6. DASVDD	11
3. 이상치 탐지 실험	12
3.1. 실험 데이터셋 소개	12
3.2. 실험 설계 및 평가 지표 소개	14
3.3. 모형 내 조율 모수 선택 방법	15
3.4. 실험을 통한 모형 성능 비교 결과	18
4. 결론	20
5. 참고문헌	21

초록

최근 정상 데이터만 이용하여 이상치 탐지 모형을 학습하는 비지도 학습 기반 모형이 활발히 연구되고 있다. 본 논문에서는 이상치 탐지에 적용되는 비지도 학습 기반의 여러 머신러닝 모형과 딥러닝 모형을 소개하고 주파수 기반의 센서 데이터에 대하여 이상치 탐지 성능을 비교하였다. 주파수 기반의 센서 데이터는 AI Hub의 누수 감지 센서 데이터를 활용하였다. 각 모형들에 대하여 자기 적응적 데이터이동 방법을 적용하여 생성된 검증 데이터를 이용하여 최적의 조율 모수를 선택하였다. 이상치 탐지의 성능 비교 결과, Autoencoder 모형과 DeepSVDD 모형을 결합한 DASVDD 모형이 가장 우수한 성능을 보였다.

주요용어: 딥러닝 모형, 머신러닝 모형, 비지도 학습, 센서 데이터, 이상치 탐지.



1. 서론 (Introduction)

이상치 (anomaly)는 기존의 데이터에서 나타나는 패턴이 아닌 다른 패턴을 갖는 데이터로 정의할 수 있으며 이러한 관측치들을 탐지해내는 과정을 이상치 탐지 (anomaly detection)라고 한다. 기존 센서 데이터에서의 이상치 탐지는 해당 분야 전문가의 지식을 기반으로 이루어졌으나, 이는 이상치 탐지까지의 시간 소모가 클 뿐만 아니라 객관적이지 못하다는 문제가 발생한다 (Martin 등, 2015). 이러한 문제점을 극복하기 위해 데이터 기반 이상치 탐지 머신러닝 및 딥러닝 모형 관련 연구가 활발히 이루어지고 있다 (Lee와 Baek, 2021; Lee 등, 2021).

이상치는 데이터에서 저빈도 (low frequency)로 발생하는 자체의 특성으로 인해 충분한 데이터를 확보하는데 큰 비용과 시간이 소모되며 이러한 특징은 데이터 내의 클래스 불균형 (class imbalance) 문제를 야기한다 (Vikram, 2020). 클래스 불균형 문제가 크게 발생한 데이터에서는 클래스 불균형 문제를 완화하는 방법을 적용하지 않을 경우에 소수의 클래스 데이터에 대한 손실 함수의 기여도가 매우 낮게 반영되어 지도학습 기반 모형의 학습이 제대로 이루어지지 않는다. 이러한 문제점을 극복하기 위해 학습 데이터 구성 시 고빈도 (high frequency) 데이터를 낮게 구성하는 언더 샘플링 (under-sampling), 저빈도 데이터를 복원 추출하여 빈도를 상향 시키는 오버 샘플링 (over-sampling), 저빈도 데이터를 합성 데이터를 통해 증강하는 SMOTE (synthetic minority over-sampling technique) 방법 등이 고려된다. 하지만 이상치 탐지 데이터에서는 기존의 불균형 문제에 적용하는 방법조차 적용이 어려울 정도로 낮은 빈도의 이상치가 포함된 경우가 많이 발생한다. 이러한 문제점을 극복하기 위하여 정상 데이터만 활용하여 이상치를 탐지하는 비지도 학습 기반의 모형이 고려되었다. 여기서의 비지도 학습 모형은 정상 데이터만을 이용하여 이상치 모형을 학습하게 되어 실제 데이터의 목표 변수 (target variable) 또는 반응 변수 (response variable)의 정보를 활용하지 않고 학습하는 모형을 나타낸다. 비지도 학습 기반의 이상치 탐지 모형은 보통 정상 데이터를 통하여 정상 데이터의 분포를 학습하고 정상 데이터의 분포에서 발생 가능성이 낮은 데이터를 이상치로 판단한다. 비지도 학습 기반 모형으로 이상치 탐지를 진행할 경우, 다른 원인으로 생성되어 새로운 분포를 따르는 이상치를 탐지하는데 우수한 성능을 보이는 것으로 알려져있다 (Barlow, 1989). 최근 비지도 학습 기반의 인공 신경망 모형이 발전함에 따라 다양한 분야의 이상치를 탐지하는데 큰 성과를 보였으나 센서 기반 관측 데이터에 대한 통합적인 비교는 충분히 제시되지 않았다. 따라서 본 연구에서는 센서 데이터에서 이상치 탐지가 가능한 비지도 학습 기반의 여러 머신러닝 및 딥러닝 모형을 소개하고 센서 데이터에 대한 이상치 탐지 성능을 비교하고자 한다.

본 논문에서는 다양한 비지도 학습 기반의 이상치 탐지 모형 중 SVM (support vector machine)을 이용한 모형인 OC-SVM (one class-support vector machine) (Schölkopf 등, 1999)과 SVDD (support vector data description) (Tax와 Duin, 2004)를 머신러닝 방법으로 고려하였고, Autoencoder (Hinton 등, 2006), AnoGAN (anomaly detection with generative adversarial networks) (Schlegl 등, 2017), Deep SVDD (Ruff 등, 2018) 및 DASVDD (deep autoencoder support vector data description) (Hojjati와 Armanfard, 2021)을 딥러닝 기반의 방법으로 고려하였다. 본 연구에서 고려한 6가지 방법으로 동일한 센서 데이터에 대해 이상치 탐지를 진행하였고 그에 대한 성능을 비교하였다. 본 논문에서 이용한 데이터는 한국지능정보사회진흥원에서 운영하는 AI 통합 플랫폼인 AI 허브 (www.aihub.or.kr)에서 제공하는 상수관로의 누수 및 파손 발생 시 상수관로의 상태 진단을 위한 주파수 센서 데이터로 주파수별 신호 강도에 대한 정보와 누수 원인에 따른 분류 정보를 제공한다. 본 연구에서는 누수가 발생하지 않은 정상 데이터만을 이용하여 비지도 학습 기반의 모형 학습과 모형 선택을 진행하고 누수가 발생한 데이터는 평가 데이터에만 활용하여 각 모형의 성능을 비교하였다.

이후 본 논문의 구성은 다음과 같다. 2장은 비지도 학습 기반 이상치 탐지 모형들을 소개하였다. 3장은 이상치 탐지에 이용한 데이터에 대한 소개와 각 모형의 조율 모수 선택 방법 그리고 이상치 탐지 성능 비교 절차를 소개하고 성능 비교 결과를 토대로 누수감지 센서 데이터에 대한 최적의 이상치 탐지 모형을 식별하였다. 마지막으로 4장에서 성능 비교 결과를 요약하고 본 연구의 결론을 제시하였다.

2. 비지도 학습 기반 이상치 탐지 모형

2.1. One-Class Support Vector Machine

One-Class SVM (OC-SVM) (Schölkopf 등, 1999)은 SVM을 이용한 비지도 학습 기반 이상치 탐지 모형이다. OC-SVM은 학습 데이터셋을 커널 기법을 이용해 새로운 특징 공간 (feature space)로 매핑하여 비선형 경계면을 학습할 수 있게 하며, 특징 공간 내 원점으로부터 최대한 멀어지도록 하는 초평면 (hyperplane)을 학습한 뒤 해당 초평면을 기반으로 이상치를 분류한다. 학습된 초평면은 학습 데이터셋에 가장 가까운 경계면이며, 해당 경계면으로부터 멀리 떨어진 데이터들을 이상치로 분류한다. 학습 데이터를 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 으로 표기하고 $\mathbf{x}_i \in \mathbb{R}^d$ 일 때, OC-SVM의 목적함수는 다음과 같이 정의한다.

$$\min_{\omega, \rho, \xi} \frac{1}{2} \|\omega\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \xi_i$$
$$\text{subject to } \omega^T \Phi(\mathbf{x}_i) \geq \rho - \xi_i, \xi_i \geq 0$$

여기서, ω 는 초평면의 법선 벡터를 나타내며, ρ 는 초평면과 원점 사이의 거리를 의미한다. ξ_i 는 슬랙 변수 (slack variable)로, 정상 데이터셋이 초평면의 양쪽에 있는 경우, 해당 데이터와 초평면 사이의 거리가 ξ_i 만큼 커질 수 있다. $\Phi(\cdot)$ 은 특징 공간으로 매핑하는 함수를 나타내며 비선형적인 경계면 학습을 위해 고려한다. 실제 모형 학습 시에는 $\Phi(\cdot)$ 함수를 직접적으로 고려하지 않고 $k(\mathbf{x}, \mathbf{y}) = \Phi(\mathbf{x})^T \Phi(\mathbf{y})$ 인 커널 함수 $k(\cdot, \cdot)$ 을 고려한다. $\frac{1}{\nu}$ 는 이상치의 비율을 나타내며, 일반적으로 $\frac{1}{\nu} \in (0, 1]$ 으로 설정한다. 따라서, $\frac{1}{\nu n}$ 은 정상 데이터셋의 비율을 나타내는 스케일링 인자이다.

위의 식은 제약조건이 있는 볼록 최적화 (convex optimization) 문제이므로 KKT (Karush-Kuhn-Tucker) 조건을 이용하여 ω, ρ 그리고 ξ 에 대한 최적해를 구한다. 식의 라그랑주 문제 (Lagrangian problem)은

$$\min_{\omega, \rho, \xi} \mathcal{L} = \frac{1}{2} \|\omega\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \xi_i - \rho - \sum_{i=1}^n \alpha_i (\omega^T \Phi(\mathbf{x}_i) - \rho + \xi_i) - \sum_{i=1}^n \beta_i \xi_i$$

이며 이 때, α 와 β 는 라그랑주 승수 (Lagrange multiplier)이다. 이에 대한 KKT 안정 조건 (KKT stationary condition)은 다음과 같다.

$$\frac{\partial L}{\partial \omega} = \omega - \sum_{i=1}^n \alpha_i \phi(x_i) = 0 \Rightarrow \omega = \sum_{i=1}^n \alpha_i \phi(x_i)$$

$$\frac{\partial L}{\partial \xi_i} = \frac{1}{\nu n} - \alpha_i - \beta_i = 0 \Rightarrow \alpha_i = \frac{1}{\nu n} - \beta_i$$

$$\frac{\partial L}{\partial \rho} = -1 + \sum_{i=1}^n \alpha_i = 0 \Rightarrow \sum_{i=1}^n \alpha_i = 1$$

위의 조건으로부터 얻은 $\omega = \sum_{i=1}^n \alpha_i \phi(x_i)$ 를 대입하여 구한 라그랑주 듀얼 문제 (Lagrange dual problem)는 다음과 같다.

$$\min_{\alpha} L = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j k(x_i, x_j) \text{ subject to } 0 \leq \alpha_i \leq \frac{1}{\nu n}, \sum_{i=1}^n \alpha_i = 1$$

위의 과정을 통해 얻은 α 의 최적해를 이용하여 구하고자 하는 ω, ρ , 그리고 ξ 에 대한 최적해를 구한다.

이상치 탐지를 위해 OC-SVM은 결정 함수 (decision function)를 이용한다. 결정 함수는 평가 데이터셋 (Test dataset)을 학습된 초평면 위로 매핑한 뒤, 해당 초평면과의 거리의 부호를 계산하는 함수이다. ω^* 는 학습된 초평면의 법선 벡터이며, ρ^* 는 학습된 초평면과 원점간의 거리일 때, OC-SVM의 결정 함수는 다음과 같이 정의한다.

$$f(x_{\text{new}}) = \text{sign}((\omega^*)^T \phi(x_{\text{new}}) - \rho^*)$$

새로운 데이터 x_{new} 는 위의 결정 함수를 통과한 함수값이 +1인 경우 정상, -1인 경우 이상치로 분류된다.

2.2. Support Vector Data Descriptor 모형

SVDD (Support Vector Data Description) (Tax와 Duin, 2004)도 OC-SVM과 마찬가지로 SVM을 이용한 비지도 학습 기반 이상치 탐지 모형이다. OC-SVM은 학습 데이터와 가장 가까운 초평면을 학습하는 반면 SVDD는 학습 데이터를 커널 기법을 고려해 비선형 경계면 학습이 가능하도록 하여, 이를 기반으로 최소한의 공간에 모든 정상 데이터를 포함하는 초구 (hypersphere)를 추정한다. 추정된 초구를 기반으로 이상치를 판단한다. 학습된 초구는 특징 공간으로 매핑된 정상 데이터셋을 감싸는 가장 작은 경계면이며, 해당 경계면으로부터 멀리 떨어진 데이터들을 이상치로 분류한다. 학습 데이터를 $x_1, x_2, \dots, x_n$ 으로 표기하고 $x_i \in \mathbb{R}^d$ 일 때, SVDD의 목적함수는 다음과 같이 정의한다.

$$\min_{R, c, \xi} \frac{1}{2} R^2 + \frac{1}{\nu n} \sum_{i=1}^n \text{subject to } \|\phi(x_i) - c\| \geq R^2 + \xi_i$$

여기서, R 과 c 는 초구의 반지름과 중점을 나타내며, ξ_i 는 슬랙 변수를 의미한다. $\phi(\cdot)$ 은 특징 공간으로 매핑하는 함수를 나타내며 실제 활용 시 커널함수

$k(\mathbf{x}, \mathbf{y}) = \Phi(\mathbf{x})^T \Phi(\mathbf{y})$ 를 이용한다. $\frac{1}{\nu n}$ 은 정상 데이터셋의 비율을 나타내는 스케일링 인자이다.

위의 식은 제약조건이 있는 볼록 최적화 문제이므로 OC-SVM과 같이 KKT (Karush-Kuhn-Tucker) 조건을 이용하여 R, c 그리고 ξ 에 대한 최적해를 구한다. 식의 라그랑주 문제 (Lagrangian problem)는

$$\min_{R, c, \xi} \frac{1}{2} R^2 + \frac{1}{\nu n} \sum_{i=1}^n \alpha_i (R^2 + \xi_i - (\Phi(\mathbf{x}_i)^T \Phi(\mathbf{x}_i) - 2 \cdot \mathbf{c}^T \Phi(\mathbf{x}_i) + \mathbf{c}^T \mathbf{c})) - \sum_{i=1}^n \beta_i \xi_i$$

이며 이 때, α 와 β 는 라그랑주 승수 (Lagrange multiplier)이다. 이에 대한 KKT 안정 조건 (KKT stationary condition)은 다음과 같다.

$$\frac{\partial L}{\partial R} = 2R - 2R \sum_{i=1}^n \alpha_i = 0 \Rightarrow \sum_{i=1}^n \alpha_i = 1$$

$$\frac{\partial L}{\partial c} = 2 \sum_{i=1}^n \alpha_i \cdot \Phi(\mathbf{x}_i) - 2c \sum_{i=1}^n \alpha_i = 0 \Rightarrow c = \sum_{i=1}^n \alpha_i \cdot \Phi(\mathbf{x}_i)$$

$$\frac{\partial L}{\partial \xi_i} = \frac{1}{\nu n} - \alpha_i - \beta_i = 0, \forall i$$

위의 조건으로 부터 얻은 값을 대입하여 구한 라그랑주 듀얼 문제 (Lagrange dual problem)는 다음과 같다.

$$\min_{\alpha} L = \sum_{i=1}^n \alpha_i k(\mathbf{x}_i, \mathbf{x}_i) - \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \text{ subject to } 0 \leq \alpha_i \leq \frac{1}{\nu n}.$$

위의 과정을 통해 얻은 α 의 최적해를 이용하여 구하고자 하는 R, c , 그리고 ξ 에 대한 최적해를 구한다.

이상치 탐지를 위해 SVDD는 결정 함수를 이용한다. 결정 함수는 평가 데이터셋 (test dataset)을 학습된 초구 안으로 매핑한 뒤, 데이터셋이 해당 초구 내에 있는지를 계산하는 함수이다. R^* 는 학습된 초구의 반지름이며, c^* 는 학습된 초구의 중점일 때, SVDD의 결정함수는 다음과 같이 정의한다.

$$f(\mathbf{x}_{\text{new}}) = \text{sign}(R^* - \|\Phi(\mathbf{x}_{\text{new}}) - \mathbf{c}^*\|)$$

새로운 데이터 $\mathbf{x}_{\text{new}}$ 는 위의 결정함수를 통과한 함수값이 +1인 경우 정상, -1인 경우 이상치로 분류된다.

2.3. Autoencoder 모형




Figure 2.1 Conceptual structure of autoencoder

Autoencoder (Hinton 등, 2006)는 학습 데이터의 정보를 축약하여 저차원의 잠재 표현(latent representation)을 학습하고 축약된 잠재 표현으로부터 원래 데이터로 복원하는 구조의 비지도 학습 기반 모형이다. Autoencoder의 구조는 Figure 2.1에 나타내었으며 이와 같이 데이터를 압축하여 잠재 표현을 추정하는 인코더(encoder)와 잠재 표현으로 압축된 데이터를 원래의 데이터로 복원하는 디코더(decoder)로 이루어져 있으며 학습 데이터와 재생성한 데이터 간의 오차(재생성 오차)를 줄이는 방식으로 학습 데이터의 분포를 학습한다. Autoencoder를 이용한 이상치 탐지 과정은 학습 데이터에 정상 데이터만을 포함하여 정상 데이터의 분포를 학습하고 학습한 데이터의 분포를 기반으로 분포에서 벗어난 데이터를 이상치로 분류한다. 학습 데이터셋을 $x_1, x_2, \dots, x_n$ 으로 표기하고, $x_i \in \mathbb{R}^d$ 일 때, Autoencoder의 목적함수는 다음과 같이 정의한다.

$$\min_{\theta, \phi} \frac{1}{n} \sum_{i=1}^n \|x_i - g_{\theta}(h_{\phi}(x_i))\|$$

여기서, $h_{\phi}(\cdot)$ 은 인코더, $g_{\theta}(\cdot)$ 은 디코더를 의미하며, ϕ 와 θ 는 각 구조 내 신경망 모형의 모수를 의미한다.

이상치 탐지를 위해 Autoencoder는 이상치 점수를 계산하여 검증 데이터셋(validation dataset)을 기반으로 임계값 기준을 구한 후 기준 이상의 이상치 점수를 갖는 데이터를 이상치로 분류한다. 이상치 점수를 계산하는 함수는 평가 데이터셋을 재생성했을 때의 재생성 오차를 계산하는 함수이다. ϕ^* 와 θ^* 는 학습된 인코더와 디코더의 모수일 때, Autoencoder의 이상치 점수는 다음과 같이 계산한다.

$$s(x_{new}) = \|x_{new} - g_{\theta^*}(h_{\phi^*}(x_{new}))\|^2$$

여기서 x_{new} 는 평가 데이터를 나타낸다.

2.4. Anomaly detection with Generative Adversarial Networks 모형




Figure 2.2 Conceptual structure of GAN

GAN (Goodfellow 등, 2014)은 적대적 생성 신경망으로 원본 데이터와 유사한 합성 데이터를 생성하는 것을 목적으로 하는 모형이다. GAN의 구조는 생성자 (generator)와 판별자 (discriminator)로 이루어져 있으며 두 개의 네트워크를 적대적으로 학습한다. 생성자 G 는 정규분포로부터 추출된 랜덤 벡터 $\mathbf{z}$ 를 실제 학습 데이터와 동일한 차원으로 매핑시켜 인공 합성 데이터를 생성하고, 판별자 D 가 실제 학습 데이터와 생성된 합성 데이터를 구별하지 못하도록 학습된다. 반면 판별자 D 는 생성자 G 로부터 생성된 합성 데이터와 실제 데이터를 잘 구별하도록 학습된다. GAN 모형의 전반적인 구조는 Figure 2.2에 나타내었다. 학습 데이터셋을 $\mathbf{X} = \{x_1, x_2, \dots, x_n\}$ 으로 표기하며 $x_i \in \mathbb{R}^d$ 일 때, GAN의 목적 함수는 다음과 같이 정의한다.

$$\min_G \max_D E_{\mathbf{X}} [\log(D(\mathbf{X}))] + E_{\mathbf{z}} [\log(1 - D(G(\mathbf{z})))]$$

여기서 $D(\mathbf{X})$ 는 실제 학습 데이터일 확률이며 판별자는 $D(\mathbf{X})$ 를 높이도록 학습한다. 반면 생성자는 실제 학습 데이터와 생성된 합성 데이터를 판별자가 구분하지 못하도록 $(1 - D(G(\mathbf{z})))$ 를 최소화하며 학습한다. 생성자의 입력값인 $\mathbf{z}$ 는 랜덤 벡터로 보통 균등 분포 또는 정규 분포에서 생성한다.

Anomaly detection with Generative Adversarial Networks (AnoGAN) (Schlegl 등, 2017)은 이상치 탐지를 위해 GAN 모형을 이용한 비지도 학습 기반의 모형으로 두 단계로 모형의 학습이 이루어진다. 먼저 첫 번째 단계에서 AnoGAN은 학습 데이터셋에 정상 데이터만 포함하여 GAN 모형의 학습을 진행하며 이를 통해 잠재 표현에 해당하는 $\mathbf{z}$ 로부터 정상 데이터의 분포를 따르는 $G(\mathbf{z})$ 를 생성할 수 있게 된다.

두 번째 단계에서는 첫 번째 단계에서 학습된 생성자와 판별자의 가중치를 고정하고 관측 데이터 x 를 목표 변수로 하여 관측 데이터와 가장 유사한 합성 데이터를 생성하는

잠재 표현 $\mathbf{z}_\gamma$ 를 찾는다. 즉, 관측 데이터 $\mathbf{x}$ 와 $G(\mathbf{z}_\gamma)$ 가 유사하도록 $L_R(\mathbf{x}, \mathbf{z}) = \|\mathbf{x} - G(\mathbf{z})\|_1$ 을 잔차 손실 함수 (residual loss function)로 정의하여 새로운 손실 함수로 고려한다.

또한 GAN 모형 구조의 판별자의 학습 정보를 반영하기 위하여 판별 기반 손실 함수를 다음과 같이 고려한다. $L_D(\mathbf{x}, \mathbf{z}) = \|f(\mathbf{x}) - f(G(\mathbf{z}))\|_1$. 여기서 $f(\cdot)$ 은 판별자 네트워크 레이어의 중간 레이어의 출력값을 의미한다.

이렇게 정의한 두 개의 손실 함수를 결합한 손실 함수 $L(\mathbf{x}, \mathbf{z}) = (1 - \lambda)L_R(\mathbf{x}, \mathbf{z}) + \lambda L_D(\mathbf{x}, \mathbf{z})$ 를 최종 손실 함수로 고려하여 주어진 $\mathbf{x}$ 에 대하여 손실 함수를 최소화하는 $\mathbf{z}_\gamma$ 를 찾게 된다. $\mathbf{z}_\gamma$ 는 잠재 표현 분포에서 랜덤하게 생성한 초기치를 기반으로 경사하강법 (gradient descent)을 통하여 반복적으로 찾게 된다. 여기서 λ 는 조율 모수로 잔차 손실 함수와 판별 기반 손실 함수의 가중치를 나타내며 Schlegl 등 (2017)에서는 $\lambda = 0.1$ 로 고려하였다.

이상치 점수는 다음과 같이

$$s(\mathbf{x}_{new}) = (1 - \lambda)L_R(\mathbf{x}_{new}, \mathbf{z}) + \lambda L_D(\mathbf{x}_{new}, \mathbf{z})$$

고려하여 정상 분포를 따르는 합성 데이터와 주어진 데이터와의 차이를 기반으로 이상치 점수를 산출한다. 여기서 $\mathbf{z}_\gamma$ 는 $\mathbf{x}_{new}$ 에 대응하는 잠재 표현으로 두 번째 단계를 통하여 찾은 잠재 표현 벡터를 나타낸다.

2.5. Deep SVDD 모형




Figure 2.3 Conceptual structure of deep SVDD

Deep SVDD (Ruff 등, 2018)는 SVDD의 목적과 같이 학습 데이터를 최소한의 공간에 모두 포함 시키는 초구를 학습하는 비지도 학습 기반 모형이며, 기존 SVDD와 달리 커널 기법이 아닌 딥러닝을 적용한 모형이다. Deep SVDD는 다음의 두 단계에 거쳐 학습된다.

- Autoencoder를 이용한 사전학습:

Deep SVDD는 SVDD와 달리 찾고자 하는 초구의 중점 c 를 Autoencoder를 이용한 사전학습을 통해 찾는다. Autoencoder를 이용하여 정상 데이터로 이루어진 학습 데이터의 잠재 표현을 학습하고 잠재 표현의 평균을 초구의 중점 c 로 설정한다.

- Deep SVDD를 이용한 초구 학습:

사전학습을 통해 얻은 초구의 중점 c 를 고정한 후 학습 데이터를 새로운 피쳐 공간으로 매핑시켜 초구의 중점 c 에 가깝게 하는 신경망 $\phi(\cdot; \Omega)$ 를 학습하는 것이 목적이다. 이 때, 신경망의 초기 가중치는 사전학습에 이용한 Autoencoder의 인코더 가중치를 초기값으로 설정하여 쉽게 초구의 중점 c 로 매핑되도록 한다. Deep SVDD모형의 전반적인 구조는 Figure 2.3에 나타내었다. 학습 데이터셋을 $x_1, x_2, \dots, x_n$ 으로 표기하고, $x_i \in \mathbb{R}^d$ 일 때, 신경망 구조 내 각 레이어의 가중치 벡터를 $\Omega = [\omega^1, \omega^2, \dots, \omega^l]$ 라 하면, Deep SVDD의 목적함수는 다음과 같이 정의한다.

$$\min_{\Omega} R^2 + \frac{1}{n} \sum_{i=1}^n \max[0, \|\phi(x_i; \Omega) - c\|^2 - R^2] + \frac{\lambda}{2} \sum_{j=1}^l \|\omega^j\|^2$$

여기서, λ 는 가중치 규제 정도를 조절하는 조율 모수이다.

Deep SVDD는 위의 목적함수를 최소화함으로써, 인공 신경망의 가중치 Ω 는 정상 데이터의 공통적 특징 요소를 기반으로 데이터가 구의 중심에 가깝게 매핑되도록 학습된다. c^* 를 사전학습을 통해 얻은 초구의 중점이라 하고 Ω^* 를 학습된 신경망 구조의 가중치라고 할 때, Deep SVDD의 이상치 탐지를 위한 이상치 점수는 다음과 같이 계산한다.

2.6. Deep Autoencoder SVDD 모형




Figure 2.3 Conceptual structure of DASVDD

Deep Autoencoder SVDD (DASVDD) (Hojjati와 Armanfard, 2021)는 Autoencoder와 Deep SVDD를 결합하여 Autoencoder의 특징인 저차원에서의 잠재 표현 학습과 SVDD의 특징인 구의 중심으로 매핑시키는 방법을 모두 활용한 모형이다. 이러한 목적을 이루기 위해 DASVDD의 구조는 재생성 오차를 줄이기 위한 Autoencoder를 학습하는 부분과 초구의 중심으로 데이터를 모으기 위한 SVDD를 학습하는 부분으로 나누어져 있으며 전반적인 구조는 Figure 2.3에 나타내었다. 학습 데이터를 $x_1, x_2, \dots, x_n$ 으로 표기하고, $x_i \in \mathbb{R}^d$ 일 때, DASVDD의 목적함수는 다음과 같이 정의한다.

$$\min_{\theta, \phi} \sum_{i=1}^n \|x_i - g_{\theta}(h_{\phi}(x_i))\|^2 + \gamma \cdot \|h_{\phi}(x_i) - c\|^2$$

여기서, $h(\cdot)$ 는 인코더 $g(\cdot)$ 는 디코더를 의미하며, ϕ 와 θ 는 각 구조 내 신경망 모형의 모수를 의미한다. 또한 $h_{\phi}(x_i)$ 는 인코더를 활용하여 얻은 잠재 표현을 의미한다. γ 는 첫번째 항과 두번째 항의 크기를 조정해주는 조율 모수이며 c 는 정규분포로부터 추출된 랜덤 벡터이다. 목적함수에서 첫 번째 항은 재생성 오차를 줄이는 것이 목적이며 두 번째 항은 초구의 경계면을 찾는 것을 목적으로 한다. ϕ^* 와 θ^* 는 학습된 인코더와 디코더의 모수일 때, DASVDD의 이상치 탐지를 위한 이상치 점수는 다음과 같이 계산한다.

$$s(x_{new}) = \|x_{new} - g_{\theta^*}(h_{\phi^*}(x_{new}))\|^2 + \gamma \cdot \|h_{\phi^*}(x_{new}) - c\|^2$$

3. 이상치 탐지 실험


3.1. 실험 데이터셋 소개

본 논문에서는 AI 허브에서 제공하는 “상수관로의 누수 및 파손 발생 시 상수관로의 상태 진단을 위한 누수 감지 센서 데이터”를 이용하여 각 모형에 대한 실험을 진행하였다. 누수 감지 센서 데이터는 상수관로에 설치된 센서를 통해 확보된 누수 감지 데이터를 기반으로 누수 여부 및 판별을 구별할 수 있도록 인공지능을 훈련하기 위한 데이터셋이다. 해당 데이터셋은 누수 탐사 전문가를 통해 누수 탐사, 적출을 통해 기록된 누수 탐사 정보를 기반으로 실제 상수관로에 누수가 일어났는지에 대해 라벨링이 진행되어 있다. 데이터셋의 클래스 구분과 각 클래스당 데이터의 수는 Table 3.1에 나타내었다.

유형	클래스	데이터(건)
누수 감지	누수	20,000(40%)
	기계 · 전기음	5,000(10%)
	환경음	5,000(10%)
	소계	30,000(60%)
누수 미감지	정상음	20,000(40%)
	소계	20,000(40%)
총계		50,000

Table 3.1 Summary of dataset

데이터의 컬럼 구성은 지역 번호, 센서 번호, 주파수 스펙트럼 밀도, 최대 감지 주파수, 최대 감지 크기 등으로 이루어져 있다. 여기서 주파수 스펙트럼 밀도는 음성 신호를 푸리에 변환을 통해 주파수 영역에서 측정된 진동수의 밀도 분포를 의미하며 주파수 해상도는 10Hz이고 범위는 0Hz 부터 5120Hz까지로 이루어져있어 주파수 센서 데이터셋에서 총 513개의 컬럼으로 이루어져있다. 각 클래스 별 평균 스펙트럼 밀도는 Figure 3.1에서 나타내었다.






Figure 3.1 클래스 별 평균 스펙트럼 밀도

본 실험에서는 이상치 탐지를 진행하기 위해 정상음 클래스를 갖는 데이터를 정상 데이터, 누수 클래스를 갖는 데이터를 이상치 데이터로 상황을 가정하여 실험을 진행하였다. 데이터셋에서 컬럼은 주파수 센서 정보만 이용하는 상황을 가정하여 주파수 스펙트럼 밀도 컬럼을 제외한 나머지 컬럼을 이용하지 않고 실험을 진행하였다.

3.2. 실험 설계 및 성능 평가 지표

본 논문에서는 학습 데이터를 기준으로 표준화를 진행하여 실험을 진행하였다. 실험은 두 가지의 시나리오를 가정하였다. 첫 번째 시나리오는 학습 데이터는 정상 데이터만으로 구성하였고 정답 레이블이 없는 상황을 가정하여 비지도 학습 기반 모형을 학습하였다. 평가 데이터는 정상 데이터와 이상치 데이터의 비율 α_l 을 바꾸어 구성하였다. 해당 시나리오를 통해 평가 데이터셋 내에 이상치 비율이 달라짐에 따라 각 모형의 성능을 비교하였다. 두 번째 시나리오는 학습 데이터 내에 이상치 데이터가 포함되었을 때를 가정하였

고 정상 데이터와 이상치 데이터의 비율 α_p 을 바꾸어 구성하였으며 평가 데이터셋 내 이상치의 비율을 0.1로 가정하여 실험을 진행하였다. 해당 시나리오에서도 학습 데이터의 정답 레이블이 없는 상황을 가정하여 비지도 학습 기반 모형을 학습하였다. 해당 시나리오를 통해 각 모형의 강건성 (robustness)을 실험하였다.

본 논문에서 진행한 실험 내 각 모형의 성능 평가 지표는 정밀도 (precision)과 재현율 (recall) 그리고 F_1 스코어를 사용하였다. 정밀도와 재현율 그리고 F_1 스코어는 다음과 같이 정의한다.


$$Precision = \frac{TP}{TP + FP}, Recall = \frac{TP}{TP + FN}, F_1 = \frac{2TP}{2TP + FP + FN}$$


여기서, P 는 이상치 데이터의 수를 의미하며, N 은 정상 데이터의 수를 의미한다. TP 는 이상치 데이터 중 모형을 통해 이상치로 분류한 데이터의 수를 의미하며, TN 은 정상 데이터 중 모형을 통해 정상으로 분류한 데이터의 수를 의미한다. FN 은 이상치 데이터 중 모형을 통해 정상으로 오분류한 데이터의 수를 의미하며, FP 는 정상 데이터 중 모형을 통해 이상치로 오분류한 데이터의 수를 의미한다. 따라서 정밀도는 모형을 통해 이상치로 분류한 데이터 중 실제 이상치인 데이터의 비율을 의미한다. 재현율은 실제 이상치 데이터 중 모형을 통해 이상치로 분류한 데이터의 비율을 의미한다. F_1 스코어는 정밀도 (precision)와 재현율 (recall)의 조화평균으로 정의하며 클래스 불균형 데이터를 분류하는 모형에서 성능 평가 지표로 활용한다.

3.3. 모형 내 조율 모수 선택 방법 소개

본 논문에서 제시한 6가지의 비지도 학습 기반 이상치 탐지 모형들은 정답 레이블이 없는 데이터를 모두 정상 데이터로 가정하여 학습하고, 이상치를 탐지하는 모형이다. 각 모형에서 조율 모수 선택은 모형 성능에 큰 영향을 미치는 중요한 과제이다. 하지만 비지도 학습 기반 모형들은 정답 레이블이 없는 데이터를 학습 데이터셋으로 사용하기 때문에 조율 모수를 평가할 수 있는 검증 데이터셋을 사용할 수 없는 문제가 생긴다. 기존 이상치 탐지 모형에서는 전문가의 지식을 기반으로 주관적인 조율 모수 선택을 하였지만 이는 한계점이 존재하였다. 따라서 본 실험에서는 학습 데이터셋을 목표 데이터셋으로 설정하여 Wang 등 (2018)에서 소개한 자가 적응 데이터 이동 (self-adaptive data shifting) 방법을 기반으로 검증 데이터셋을 생성하고 각 모형 내의 조율 모수를 설정하였다. 자가 적응 데이터 이동 방법은 목표 데이터셋의 경계 패턴을 인식하고 경계 패턴의 주변 데이터의 정보를 기반으로 정상 데이터 분포의 밀도 함수가 낮아지는 방향 (즉, 밀도 함수의 음의 그래디언트 (gradient) 방향)으로 데이터를 이동시켜 의사 이상치 (pseudo anomaly)를 생성한다. 또한 추가된 의사 이상치의 영향을 보정하기 위하여 추정한 밀도 함수의 그래

디언트의 양의 방향으로 이동된 데이터를 의사 목표 데이터 (pseudo target data)로 정의하여 추가한다. 보다 상세히 설명하면, 먼저 의사 이상치를 생성하기 위해 감지한 경계 패턴을 기반으로 데이터를 이동시키는 방향과 크기를 정의한다. 이동시키는 방향은 목표 데이터 밀도 함수의 그래디언트에 음의 방향이며 Fukunaga (2013)에서 소개한 방법으로 밀도 함수의 그래디언트를 근사하여 추정한다. Fukunaga (2013)의 방법은 경계 패턴의 k 개의 최근접 이웃 데이터 (k -nearest neighbor data)를 찾고 해당 데이터로부터 방향 벡터를 구한 뒤 이를 이용하여 밀도 함수의 그래디언트를 추정하며 이에 대한 과정을 Figure 3.2에 나타내었다.





(c) Pseudo target data generation

Figure 3.2 Process of self adaptive data shifting method

경계 패턴은 x_i 이고 k 개의 최근접 이웃 데이터는 $x_{i1}, x_{i2}, \dots, x_{ik}$ 이며 그에 대한 방향 벡터는 $v_{ij} = \frac{(x_i - x_{ij})}{\|x_i - x_{ij}\|}$ 일 때, 밀도 함수의 그래디언트 $-\nabla p(x)$ 는 다음과 같이 계산한다.

$$-\nabla p(x_i) \simeq n_i - \sum_{j=1}^n v_{ij}$$

그 다음 의사 이상치를 생성하기 위해 경계 패턴에 대하여 이동시키는 크기를 다음의 방법으로 정의한다. 먼저 경계 패턴과 그에 대한 k 개의 최근접 이웃 데이터 간의 거리의 평균을 구하고 이 과정을 모든 경계 패턴에 적용하여 계산한 후 모든 값의 평균을 크기로 설정한다. 이 과정을 정리하면 다음과 같다.

$$\overline{l_{ns}} = \frac{1}{|\mathbf{X}_{edge}|} \sum_{x_i \in \mathbf{X}_{edge}} \frac{1}{k} \sum_{j=1}^k \|x_i - x_{ij}\|$$

위의 과정을 통해 얻은 방향과 크기를 이용하여 의사 이상치셋은 다음과 같이 생성하였으며 전반적인 과정을 Figure 3.2(b)에 나타내었다.

$$\mathbf{X}_{anomaly} = \{x_o^{(i)} | x_o^{(i)} = x_i + \frac{-\nabla p(x_i)}{\|-\nabla p(x_i)\|} \cdot \overline{l_{ns}}, \forall x_i \in \mathbf{X}_{edge}\}$$

의사 목표 데이터를 생성하기 위해 데이터에서 k 개의 최근접 이웃 데이터로부터 방향 벡터를 구한다. 방향 벡터와 위에서 추정된 밀도 기울기를 내적 하였을 때 값이 0보다 큰 최근접 이웃 데이터 중 밀도 함수의 그래디언트 벡터에 사영한 데이터를 후보 데이터 (candidate data)로 한다. 의사 목표 데이터는 앞에서 정의한 후보 데이터 중 가장 가까운 데이터로 생성하며 전반적인 과정을 Figure 3.2(c)에 나타내었다. 목표 데이터는 x_i 이며 그에 해당하는 k 개의 최근접 이웃 데이터는 $x_{i1}, x_{i2}, \dots, x_{ik}$ 일 때, 의사 목표 데이터셋은 다음과 같이 생성한다.

$$\mathbf{X}_{pseudotgt} = x_t^{(i)} | x_t^{(i)} = x_i + \left\langle \frac{-\nabla p(x_i)}{\|-\nabla p(x_i)\|}, x_{ij}^{\min+} - x_i \right\rangle \cdot \frac{-\nabla p(x_i)}{\|-\nabla p(x_i)\|}, \forall x_i \in \mathbf{X}_{target}$$

여기서 $\langle x, y \rangle$ 는 두 벡터 x, y 의 내적을 의미하며 $x_{ij}^{\min+}$ 은 방향 벡터와 위에서 추정된 밀도 함수의 그래디언트를 내적 하였을 때 값이 가장 작은 최근접 이웃 데이터를 의미하며 다음과 같이 정의한다.

$$x_{ij}^{\min+} = \min_{x_{ij} \in \Lambda_i^+} \left\langle \frac{-\nabla p(x_i)}{\|-\nabla p(x_i)\|}, x_{ij} - x_i \right\rangle$$

이 때, Λ_i^+ 는 방향 벡터와 위에서 추정된 밀도 기울기를 내적하였을 때 값이 0보다 큰 최근접 이웃 데이터들의 집합을 의미한다.

생성된 의사 이상치 데이터와 의사 목표 데이터를 이용하여 검증 데이터셋을 구성하였으며 검증 데이터셋을 기반으로 각 모형의 조율 모수와 이상치 점수에 대한 임계값을 설정하였다.

3.4. 모형 성능 비교 결과

본 논문에서 진행한 실험은 3.1절에 소개한 실험 데이터셋을 통해 각 모형의 성능을 본 실험에서 고려한 두 가지의 시나리오를 가정한 후 10번의 반복 실험을 진행하였으며, 성능 평가 기준은 3.2절에 소개한 정밀도와 재현율 그리고 F_1 스코어를 통해 평가하였다. 또한 실험에서 고려한 모든 모형들은 3.3절에서 소개한 조율 모수 선택 방법을 통해 검증 데이터셋을 기반으로 각 모형에서 생성한 데이터셋을 기반으로 이상치를 분류하였을 때의 F_1 스코어를 기준으로 비교하여 모형의 구조와 최적의 조율 모수를 선택하였다.

OC-SVM 모형과 SVDD 모형에서는 동일하게 방사형 커널 (Radial Basis Function)을 사용하고 조율모수 ν 는 0.1 γ 는 0.01을 선택하였을 때 가장 좋은 F_1 스코어를 기록하였으며 이를 조율 모수로 선택하였다. Autoencoder 모형과 DASVDD 모형에서는 에폭 (epoch)을 100 그리고 배치 사이즈는 512로 설정하였고 AnoGAN 모형에서는 에폭을 200 그리고 배치 사이즈는 1024로 설정하였으며 Deep SVDD 모형에서는 에폭을 50 그리고 배치 사이즈는 512로 설정하였다. 각 시나리오 별 평가 데이터에 대한 이상치 탐지 실험 결과는 Table 3.2과 Table 3.3에 요약하였다.

Method	$\alpha_l = 0.01$			0.05			0.1		
	Precisi on	Recall	F_1	Precisi on	Recall	F_1	Precisi on	Recall	F_1
OC-SVM	0.65	0.22	0.32	0.60	0.57	0.59	0.61	0.73	0.67
SVDD	0.63	0.28	0.38	0.61	0.56	0.59	0.61	0.71	0.66
Autoencoder	0.68	0.22	0.34	0.60	0.56	0.58	0.60	0.63	0.61
AnoGAN	0.14	0.14	0.14	0.46	0.46	0.46	0.57	0.56	0.57
DeepSVDD	0.54	0.20	0.28	0.55	0.61	0.57	0.57	0.70	0.62
DASVDD	0.71	0.21	0.32	0.70	0.57	0.63	0.70	0.71	0.70

Method	$\alpha_l = 0.2$			0.3		
	Precisi on	Recall	F_1	Precisi on	Recall	F_1
OC-SVM	0.62	0.84	0.72	0.61	0.87	0.72
SVDD	0.60	0.84	0.71	0.64	0.87	0.73
Autoencoder	0.66	0.75	0.69	0.61	0.78	0.68
AnoGAN	0.64	0.65	0.64	0.70	0.70	0.70
DeepSVDD	0.51	0.82	0.62	0.53	0.88	0.65
DASVDD	0.70	0.84	0.76	0.70	0.89	0.78

Table 3.2 Summary of performance for anomaly detection on the scenario 1

Method	$\alpha_l = 0.01$			0.05			0.1		
	Precisi on	Recall	F_1	Precisi on	Recall	F_1	Precisi on	Recall	F_1
OC-SVM	0.54	0.75	0.63	0.46	0.30	0.35	0.77	0.07	0.13
SVDD	0.53	0.73	0.62	0.49	0.32	0.38	0.76	0.07	0.13
Autoencoder	0.59	0.72	0.66	0.62	0.14	0.23	0.59	0.11	0.19
AnoGAN	0.55	0.55	0.55	0.43	0.43	0.43	0.28	0.27	0.28
DeepSVDD	0.50	0.68	0.56	0.50	0.45	0.45	0.53	0.27	0.32
DASVDD	0.67	0.73	0.70	0.62	0.34	0.44	0.59	0.11	0.19

Method	$\alpha_l = 0.2$			0.3		
	Precisi on	Recall	F_1	Precisi on	Recall	F_1
OC-SVM	0.75	0.09	0.14	0.83	0.05	0.09
SVDD	0.76	0.10	0.16	0.82	0.07	0.10
Autoencoder	0.57	0.10	0.18	0.60	0.10	0.18
AnoGAN	0.19	0.18	0.19	0.11	0.11	0.11
DeepSVDD	0.54	0.14	0.22	0.52	0.12	0.18
DASVDD	0.59	0.11	0.19	0.59	0.11	0.18

Table 3.3 Summary of performance for anomaly detection on the scenario 2

첫 번째 시나리오에서 평가 데이터셋 내에 이상치의 비율 α_l 은 [0.01, 0.05, 0.1, 0.2, 0.3]로 설정하여 실험을 진행하였으며 이상치의 비율이 커짐에 따라 재현율과 F_1 스코어는 상승하는 경향을 보였다. 본 실험에서 고려한 모형 중 Autoencoder의 장점과 Deep SVDD의 장점을 결합한 모형인 DASVDD 모형이 전반적으로 가장 좋은 성능을 기록하였다. 두 번째 시나리오에서 학습 데이터셋 내에 이상치의 비율 α_p 은 [0.01, 0.05,

0.1, 0.2, 0.3]로 설정하여 실험을 진행하였으며 이상치의 비율이 커짐에 따라 정밀도는 상승하는 경향을 보였으며 재현율과 F_1 스코어는 크게 하락하는 경향을 보였다. 이는 현재 성능 비교를 고려한 비지도 학습 기반 모형은 훈련 데이터는 모두 정상 데이터로 가정하여 개발된 모형으로 모형의 가정이 위배 되는 정도가 높아질수록 성능이 저하되는 자연스러운 경향이라고 판단된다.

본 실험에서 고려한 모형 중 신경망 구조를 갖는 딥러닝 모형의 성능이 전반적으로 우수하였으며 재생성 오차를 기반으로 학습하지 않는 Deep SVDD모형의 성능이 가장 좋은 성능을 기록하였다. 이는 학습 데이터셋 내의 이상치가 재생성 오차에 큰 영향을 주는 것으로 판단된다. 이러한 결과를 기반으로 주파수 센서 데이터를 대상으로 한 이상치 탐지 모형은 학습 데이터셋 내에 이상치가 없는 경우 DASVDD 모형을 제안하며, 학습 데이터셋 내에 이상치가 포함된 경우 Deep SVDD 모형을 제안한다.

4. 결론

본 논문은 실제 상수관로의 상태 진단을 위한 주파수 센서 데이터를 이용하여 비지도 학습 기반의 이상치 탐지 모형들의 성능과 훈련 시간을 비교하였다. 실험에 고려한 모형은 OC-SVM, SVDD, Autoencoder, AnoGAN, Deep SVDD, DASVDD 총 6가지의 모형이다. 실험에서 두 가지 시나리오를 가정하였으며 첫 번째 시나리오에서 Autoencoder의 장점과 Deep SVDD의 장점을 결합한 DASVDD 모형이 대체적으로 우수함을 확인하였고 두 번째 시나리오에서 재생성 오차를 기반으로 하지않은 Deep SVDD 모형이 대체적으로 우수함을 확인하였다. 따라서 주파수 센서 데이터에서의 이상치 탐지 시 학습 데이터 내에 이상치가 포함되지 않은 경우 DASVDD 모형, 학습 데이터 내에 이상치가 포함되었을 경우 Deep SVDD 모형을 고려하는 것을 제안한다.

본 논문에서 고려한 모형들은 모두 학습 데이터셋에 레이블이 없는 데이터를 이용한 비지도 학습 기반 이상치 탐지 모형으로 학습 데이터는 모두 정상 데이터임을 가정하고 있다. 최근 소량의 레이블이 있는 데이터를 이용하여 학습하는 준지도학습(semi-supervised learning)기반 이상치 모형들이 제안되고 있으며 정상 데이터와 정상/비정상이 알려지지 않은 Unlabeled 데이터가 혼합된 형태의 Positive and Unlabeled Data에 대한 연구도 최근에 진행되고 있어 이러한 방법론들에 대해서는 추후 성능 비교 연구를 고려하고 있다.

5. 참고 문헌

- [1]. Barlow, H. B. (1989). Unsupervised learning. Neural computation, 1, 295--311.
- [2]. Fukunaga, K. (2013). Introduction to statistical pattern recognition. Elsevier.
- [3]. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville A. and Bengio Y. (2014). Generative adversarial nets. Advances in neural information processing systems, 2672--2680.
- [4]. Hinton, G. E. and Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. Science, 313, 504--507.
- [5]. Hojjati, H. and Armanfard, N. (2021). Dasvdd: Deep autoencoding support vector data descriptor for anomaly detection. arXiv:2106.05410.
- [6]. Lee, K. and Baek, C. (2021). Outlier detection for long memory processes. Journal of the Korean Data & Information Science Society, 32, 1205--1218.
- [7]. Lee, C. W., An, S-Y., Kim, J-Y., and Ahn, H. (2021). Sensor anomaly detection system in greenhouse-type smart farm using environmental data. Journal of the Korean Data & Information Science Society, 32, 1237--1248.
- [8]. Marti, L., Sanchez-Pi, N., Molina, J.M., and Gracia, A.C.B. (2015). Anomaly detection based on sensor data in petroleum industry application. Sensors, 15, 2774--2797.
- [9]. Ruff, L., Vandermeulen, R., Goernitz, N., Deecke, L., Siddiqui, S. A., Binder, A., Muller, E., and Kloft, M. (2018). Deep one-class classification. In International conference on machine learning, 4393--4402.
- [10]. Schlegl, T., Seeböck, P., Waldstein, S. M., Schmidt-Erfurth, U. and Langs, G. (2017). Unsupervised anomaly detection with generative adversarial networks to guide marker discovery. In Information Processing in Medical Imaging: 25th International Conference, IPMI 2017, Boone, NC, USA, June 25-30, 2017, Proceedings, 146--157.
- [11]. Schölkopf, B., Williamson, R. C., Smola, A., Shawe-Taylor, J. and Platt, J. (1999). Support vector method for novelty detection. Advances in neural information processing systems, 12, 1--7.
- [12]. Vikram, A. (2020). Anomaly detection in network traffic using unsupervised machine learning approach. 2020 5th International Conference on Communi-

cation and Electronics Systems, 476--479.

[13]. Wang, S., Liu, Q., Zhu, E., Porikli, F., and Yin, J. (2018).

Hyperparameter selection of one-class support vector machine by self-adaptive data shifting. Pattern Recognition, 74, 198--211.

